

Seminario 3

Estimadores de máxima Verosimilitud

La verosimilitud de una muestra.

A la densidad conjunta evaluada en la muestra, se la llama **función de verosimilitud** (**versemblança / likelyhood**) **de la muestra**.

Es una V.A. con valores en \mathbf{R}^+ .

Denotaremos por

$$L(X_1, \dots, X_n; \theta) = \prod_{i=1}^n f(X_i; \theta)$$

donde $f(x; \theta)$ es la densidad de las X_i (o la función de probabilidades en el caso discreto), a la función de verosimilitud, y por

$$\lambda(X_1, \dots, X_n; \theta) = \sum_{i=1}^n \log f(X_i; \theta)$$

al logaritmo de L .

El método de máxima verosimilitud consiste en utilizar como estimador de θ el valor $\hat{\theta}$ que maximiza la verosimilitud de la muestra.

El **estimador de máxima verosimilitud**¹ $\hat{\theta}$ es aquél que verifica

$$L(X, \hat{\theta}) \geq L(X, \theta)$$

para todo θ en el espacio de parámetros.

La función de densidad $f(x; \theta)$ (o en su caso la probabilidad $p(x; \theta) = \mathbf{P}\{X = x\}$) nos da una medida intuitiva de cuánto podemos confiar en que ocurra x una vez que conocemos θ , pero también nos permite comparar esas medidas para distintos valores del parámetro θ . Particularmente, una vez que hemos observado x , $f(x; \theta)$ nos indica hasta qué punto era esperable el resultado observado, cuando el parámetro vale θ .

Encontraremos entonces que el modelo probabilístico dado por $f(x; \theta')$ resulta más creíble (o más verosímil) que el modelo definido por $f(x; \theta'')$ cuando ocurra $f(x; \theta') > f(x; \theta'')$.

En este contexto, podemos decir que el método de máxima verosimilitud propone utilizar como estimador del parámetro, el valor que vuelve más creíble o más *esperable* el resultado que de hecho ha sido observado experimentalmente.

1 Cálculo de los estimadores de máxima verosimilitud con R

La librería **MASS** tiene una función (**fitdistr**) que calcula el MLE para algunas distribuciones:

¹puede no ser único, puede que no exista

```
library(MASS)
?fitdistr      # help sobre la función

##### exponenciales
x=rexp(100,rate=2)#rate es lambda
fitdistr(x,"exponential")
1/mean(x) ## comprobamos que el estimador es el que conocemos
##### normales
n=100
y=rnorm(100,3,6) #media=3, desviación=6
fitdistr(y,"normal")
## comprobamos que los estimadores son los que conocemos:
mean(y); var(y)*(n-1)/n; sqrt(var(y)*(n-1)/n)
```

- Hay otra librería (`fitdistrplus`) que incluye más modelos.
- El cálculo del máximo de la verosimilitud también se puede hacer con `nlm` o con `optim` (rutinas de optimización de R). Estas rutinas minimizan funciones, por lo tanto hay que escribir una función que contenga $-\log L(X_1, \dots, X_n; \theta)$, donde $\theta \in \mathbb{R}^p$.

1.1 Ejemplo - el MLE para el parámetro λ de una distribución exponencial:

Generar una muestra de tamaño 100 y $\lambda = 2$,

```
x=rexp(100,rate=2)
mean(x);1/mean(x)
##definimos una funcion con -log(verosimilitud)
mlogL=function(x,lam=1){return(-(length(x)*log(lam)-lam*sum(x)))}
```

En realidad no hace falta escribir en este caso la verosimilitud, pues R la puede calcular:

```
mlogl=function(x,lam=1){return(-sum(dexp(x,rate=lam, log = TRUE))) }
##### d son las densidades, log=TRUE su logaritmo
```

```
##### Gráfico de log(verosimilitud)
npoint <- 101
lams <- seq(min(x), max(x)+2, length = npoint)
logls <- numeric(npoint)
for (i in 1:npoint)
  logls[i] <- mlogl(x,lams[i])
plot(lams, -logls, type = "l",
     xlab = expression(lams), ylab = expression(l(lams)))
```

```
#### Cálculo del máximo usando nlm y optim
```

```
nlm(mlogl, 1, x = x)
optim(1,mlogl,x=x)
1/mean(x)
```

Ejercicios

1. Escribir una función que calcule la -log-verosimilitud para una muestra de variables aleatorias con distribución normal de media y varianza desconocidas. Usarla para estimar los parámetros de una muestra de tamaño 100 generada con $\mu = 3, \sigma = 2$ con `nlm`.
2. Calcular los estimadores de máxima verosimilitud de μ y σ^2 para los datos de Michelson de la librería `MASS`. ¿Es razonable pensar que son normales? Repetir el cálculo eliminando el posible outlier.
3. La següent taula mostra distribució del nombre de pars de bambes per a un grup de 60 corredors aficionats.

Nombre de pars:	1	2	3	4	5
Freqüència:	18	18	12	7	5

La distribució de Poisson no pot ser un bon model per a aquestes dades, perquè se suposa que els corredors tenen almenys un par de bambes. La distribució de Poisson truncada (en zero) amb funció de massa de probabilitats

$$p(x; \theta) = \frac{\theta^x e^{-\theta}}{x!(1 - e^{-\theta})}, \quad x = 1, 2, \dots, \quad \theta > 0$$

pot ser un model més adient.

- (a) Escriure la versemblança, el Score i la informació observada.
 - (b) Trobar (numèricament) l'estimador de màxima versemblança de θ .
4. En la librería `evir` hay un conjunto de datos llamado `danish` que corresponde a los montos de reclamaciones por incendios hechas a aseguradoras en Dinamarca entre el 3 de enero de 1980 y el 31 de diciembre de 1990. Supongamos que provienen de una distribución de Pareto, con densidad

$$f(x) = \frac{\alpha x_m^\alpha}{x^{\alpha+1}} \quad \text{si } x \geq x_m$$

y 0 si $x < x_m$.

- (a) Calcular el EMV para los parámetros α y x_m de la distribución de Pareto. Observar que x_m está en la frontera del espacio de parámetros.
5. Las densidades Gamma pertenecen a una familia de distribuciones continuas con dos parámetros. La exponencial y la χ^2 son casos particulares de densidades Gamma. Hay tres parametrizaciones de uso común:
 - Con un parámetro de forma (shape) k y uno de escala (scale) θ .
 - Con un parámetro de forma (shape) $\alpha = k$ y un parámetro (rate) que es la inversa del parámetro de escala, $\beta = 1/\theta$
 - Con un parámetro de forma (shape) k y la media $\mu = k/\beta$.

En cada una de estas tres formas, los parámetros son números reales positivos.

Si usamos la segunda de las parametrizaciones, una V.A. $X \sim \Gamma(\alpha, \beta)$ la densidad de X es

$$f(x; \alpha, \beta) = \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x}$$

donde $\Gamma(\alpha) = \int_0^\infty x^{\alpha-1} e^{-x} dx$

Los estimadores de máxima verosimilitud no admiten una forma cerrada, así que hay que calcularlos numéricamente.

- (a) Generar una muestra de tamaño 100 de una $\Gamma(10, 3)$ `x=rgamma(100,shape=10,rate=3)`
- (b) Encontrar los estimadores que da el método de los momentos, para usarlos como valores iniciales en el cálculo de los MLE.
- (c) Calcular los estimadores de máxima verosimilitud.